

Document Image Preprocessing

2026.04.14

이지원


Problem Setting

- 입력 이미지의 퀄리티가 떨어지는 경우 document parsing의 정확도
- 텍스트 인식률을 높이기 위해 탐지 대상을 명확히 하는 전처리 절차

[illegible][illegible][illegible]

Proposed Method

Full Pipeline



문서 영역 탐지 및 분리

1. EXIF 메타데이터 확인

- 스캐너 키워드 (epson 등) → scan
- 카메라 키워드 (iphone, samsung 등), GPS 정보 → camera

2. Screenshot 감지

- pdf 뷰어 패턴 (어두운 테두리 + 밝은 내부)
- 일반 스크린샷 (flat 픽셀 비율 높음 + 표준 화면 비율)

3. 6개 feature 투표: score ≥ 2 → scan 확정


- border_white_ratio > 0.9 → +1 (가장자리 흰 픽셀 비율)
- contour_ratio > 0.85 → +1 (최대 윤곽선 면적 비율)
- brightness_variance < 800 → +1 (밝기 분산 낮음)
- DPI ≥ 600 → +1 (메타데이터)
- illum_uniformity < 150 → +1 (조명 균일)
- sharpness > 300 → +1 (선명도)

Proposed Method

문서 영역 탐지(Segmentation) 및 분리

사용 모델: Fine-tuned YOLOv8s-seg



- **base model:** yolov8s-seg.pt (coco 데이터셋)
- **finetuned model:** base model을 일반 문서 데이터셋 + 도메인 특화 데이터셋으로 추가학습 (일반 문서 데이터셋 1,763장, 도메인 특화 데이터셋 128장)





Proposed Method

문서 영역 탐지(Segmentation) 및 분리


Yolov8s-seg
(baseline)







finetuned Yolov8s-seg with
general document images



finetuned Yolov8s-seg with
specialized document images



DocAligner



[illegible]

[illegible]

Proposed Method

합본 이미지 여부 판단 및 분리

1. 합본 여부 판단

- 비율 확인

가로/세로 비율 ≥ 2.0 이면 합본 의심 $\rightarrow$ PaddleOCR 실행

2. 페이지별 분리:Paddle OCR (Detection + Recognition)

- 문서 제목 텍스트 (ex-자동차등록원부) + 위치 탐지 (y좌표)
- 각 페이지 시작점 = 헤더 위 30px
- y 좌표 간격으로 이미지 분리

진본
2025-12-02
14:24:35
합본 확인 완료

문서확인번호: 8637612373400224
■ 자동차등록규칙 [별지 제3호서식] <개정 2025. 2.17>

자동차등록원부(갑) 등본·초본
(각종·자동차등록부, 각도·2257)

제	000828	호	총 4 면 중 제 1 면		
자동차등록번호	48수4780	제원관리번호	A08-1-00044-0053-1204	일소등록일	2020-03-09
차 명	뉴아반떼XD(NEW AVANTE XD)		차 종	승용 중형	
차대번호	KMHDN41AP5U129936	원동기형식	G4EC	용 도	자가용
구동축전지 식별번호(전기자동차만 해당)					
모델연도	2005	색 상	출처구분 전입차		
최초등록일	2005-05-04	세부유형(운수사업용자동차만 해당)	제작연월일	2005-04-28	
최종소유자	김현수		최초 양도연월일		
사용본가지 (차고지)	서울특별시 용산구 *****		주민등록번호(법인등록번호)	810126-*****	
검사 유효기간	2019-05-04 ~ 2021-05-03		주행거리 : 223216Km	등록사항 확인일	폐쇄일
순 위 번 호	사 항 란		주민등록번호 (법인등록번호)	등 록 일	접수번호
주등록	부기등록				
1-1		신규등록(신차) 성명(상호): 오*아 781019-***** 주소: 서울특별시 은평구 *****	781019-*****	2005-05-04	088120
1-4		변경등록 주소: 서울특별시 은평구 *****		2005-10-04	211682
1-7		변경등록 주소: 서울특별시 은평구 *****		2006-08-01	165108
1-19		변경등록 주소: 서울특별시 은평구 *****		2008-06-13	136431
1-20		변경등록(단순전출) 성명(상호): 오*아 781019-***** 주소: 경기도 김포시 ***** 신차등록번호: 02재8467		2008-08-01	192398
1-1		변경등록(전입) 성명(상호): 오*아 781019-***** 주소: 경기도 김포시 ***** 구자동차번호: 02재8467	781019-*****	2008-08-01	163438
**** 다음장 계속 ****					

이 등본은 자동차등록원부(갑)의 기재사항과 틀림없음을 증명합니다. 2025년 12월 02일

서울특별시 용산구청장

◆ 자동차365(car365.go.kr)의 인터넷발급문서확인 메뉴를 통해 위·변조 여부를 확인할 수 있습니다. (발급일로부터 90일까지) 또한 문서 하단의 바코드도 진위확인(정확 24 점 또는 스캐너를 문서확인 프로그램에 접속할 수 있습니다).

30px ↑

자동차등록원부(갑) 등본·초본
(각종·자동차등록부, 각도·2257)


제	000828	호	총 4 면 중 제 2 면		
자동차등록번호	48수4780	제원관리번호	A08-1-00044-0053-1204	일소등록일	2020-03-09
차 명	뉴아반떼XD(NEW AVANTE XD)		차 종	승용 중형	
차대번호	KMHDN41AP5U129936	원동기형식	G4EC	용 도	자가용

30px ↑

문서확인번호: 8637612373400224
 ■ 자동차등록규칙 [별지 제3호서식] <개정 2025. 2.17>

자동차등록원부(갑) 등본-초본
(약형·자동차전부입, 약소·C257A)

계	000828	호	총 4 면 중 계 2 면
자동차등록번호	48수4780	제원관리번호 A08-1-00044-0053-1204	발소등록일 2020-03-09
차 명	뉴이반데XD(NEW AVANTE XD)		차 종 승용 중형
차대번호	KMH0N141A5U129936	원동기형식 G4EC	용 도 자가용



기타 전처리

원근보정 (Perspective Warp)

- 노이즈 제거
- 외각 contour 추출 → 꼭짓점 4개 추출 → [TL, TR, BR, BL] 순으로 정렬 (order_corners)
- 직사각형으로 변환
 $w = \max(|TR-TL|, |BR-BL|)$ # 위아래 변 중 긴 쪽
 $h = \max(|BL-TL|, |BR-TR|)$ # 좌우 변 중 긴 쪽

미세 기울기 보정 (Deskew)

- gray → Canny 엣지 → HoughLinesP로 직선 검출
- 각 직선의 기울기 각도 계산 → 기울기 중간값 < 0.5 미만이면 스킵


1001

		번호: B-27 문서확인번호: 8637612373400224 ■ 자동차등록번호 [별지 제3호서식] C개령 2025. 2. 17	
자동차등록원부(갑) 등본·초본 [양식: 자동차위반과 약호: C257A]			
제	000828	호	총 4 면 중 제 1 면
자동차등록번호	48구4780	계관관리번호	A08-1-00044-0053-1204
차 명	뉴아반떼KD(NEW AVANTE KD)		차 종 승용 차량
차대번호	KMHND41APSU129935	원동기형식	G4EC
주요속한자 식별번호(인가자출처는 해당)			
모델연도	2005	색 상	출처구분 전입차
최초등록일	2005-05-04	세무유형(문수사업용자동차만 해당)	제작연월일 2005-04-28
최종소유자	김현수		최초 영도 연월일 주민등록번호(주민등록번호)
사용할거처 서울특별시 용산구			810126*****
영사 유효기간 2019-05-04 ~ 2021-05-03	주행거리: 223216Km		등록사항 확인일 개폐일
순 위 번 호			
주 동 령 부 기 록 른 사 항 한	중대교통범죄(일반교통범죄)	등 록 일	접 수 번 호
1-1	신규등록(신조차) 성명(성호): 오+야 781019-***** 주소: 서울특별시 은평구 *****	781019-*****	2005-05-04 088120
1-4	변경등록 주소: 서울특별시 은평구 *****		2005-10-04 211682
1-7	변경등록 주소: 서울특별시 은평구 *****		2006-08-01 165108
1-19	변경등록 주소: 서울특별시 은평구 *****		2008-06-13 136431
1-20	변경등록(단순전출) 성명(성호): 오+야 781019-***** 주소: 경기도 김포시 ***** 신자율번호: 02가6667		2008-08-01 192398
1-1	변경등록(전입) 성명(성호): 오+야 781019-***** 주소: 경기도 김포시 ***** 구자동차번호: 02가6667	781019-*****	2008-08-01 163438
*** 다음장 계속 ***			
[참고사항] 이 등본은 자동차등록원부(가)의 기재사항과 통행료를 증명합니다.		[참고사항] 2025년 12월 02일	
서울특별시 용산구청			
[참고사항] * 자동차365(gar365.go.kr)와 인터넷공공서비스 메뉴를 통해 위 변조 여부를 확인할 수 있습니다. (행정안전부 90일가치 포함 문서 해당의 비효율적도 있음)(참조) 24. 1월 29일 - 소관기관에서 확인 요청을 받았으나 응답하지 않았습니다.			
			

Proposed Method


Full Pipeline Example

[Original] 1.jpg



[YOLO] conf=0.985
detected: 1

[Crop] perspective warp



[Source Classifier]

CAMERA
conf: 100%

feature value

border_white_ratio	0.010 (-)
contour_ratio	0.078 (-)
brightness_variance	3304.200 (-)
illum_uniformity	1286.400 (-)
sharpness	2997.000 (+)
dpi	96.0 (-)

>> com_override: True


[Orientation] angle=0deg conf=0.876 (OK)
before ??? after (applied)



[Final] elapsed=1700ms
source=camera angle=0deg


detector: 0.50
label: 0.51
text: 0.51

[Original] 4877747



[YOLO] skipped

[Crop] perspective warp




[Source Classifier]

SCAN
conf: 33%

feature value

border_white_ratio	0.862 (-)
contour_ratio	0.065 (-)
brightness_variance	3970.400 (-)
illum_uniformity	15.200 (+)
sharpness	3621.600 (+)
dpi	95.9660 (-)


[Orientation] angle=0deg conf=0.924 (OK)
before ??? after (skipped (low conf))



[Final] elapsed=34731ms
source=scan angle=0deg


detector: 0.50
label: 0.51
text: 0.51

OCR 정확도 비교



—등록이력 (6건)

[신규등록1	] 신규등록(신조차) 성명(상호):오*아 781019-***** 주소:서... 781019-*****
[변경등록1	] 변경등록 주소: 서울특별시 은평구 *** *... *... *
[변경등록2	] 변경등록 주소: 서울특별시 은평구 *** *... *... *
[변경등록3	] 변경등록 주소:서울특별시 은평구 *** *... *... *
[변경등록4	] 변경등록(단순전출) 781019-***** 성명(상호)도오*아시 *...]
[변경등록5	] 변경등록(전입) 781019-***** 성명(상품) ... *... *... 781019-*****




—등록이력 (6건)

[신규등록1	] 신규등록(신조차) 성명(상호) : 오*아 781019-***** 주소... 781019-*****
[변경등록1	] 변경등록 주소:서울특별시 은평구 *** ★★★★★★★★★★★★★★...
[변경등록2	] 변경등록 주소:서울특별시 은평구 ★★★★★★★★★★★★★★...
[변경등록3	] 변경등록 주소:서울특별시 은평구 ★★★★★★★★★★★★★★...
[변경등록4	] 변경등록(단순전출) 성명(상호) : 오*아 781019-***** 주...
[변경등록5	] 변경등록(전입) 성명(상호) :오*아 781019-***** 주소: ... 781019-*****

Experiments & Results

OCR 정확도 비교



— 기본정보 —
차량등록번호 : 48수4780
차대번호 : **KMHON41APSU129935**
최종소유자 : 김현수
최종소유자_주민번호 : 810126-*****

— 등록이력 (6건) —
[신규등록1]] 신규등록(신조차) **성명(상호)** 781019-***** 은평구 *** ... | 781019-*****
[변경등록1]] 변경등록 주소:서울특별시 은평구 *****
[변경등록2]] 변경등록 주소: 서울특별시 은평구 *****
[변경등록3]] 변경등록 주소; 서울특별시 은평구
[변경등록4]] **변경등록(단순전출) 781019-***** 신자문화번호:02-02 *...**
[변경등록5]] 변경등록(전입); 오+아 781019-***** 부족발행일로 김포시... | 781019-*****



— 기본정보 —
차량등록번호 : 48수4780
차대번호 : **KMHON41APSU129935**
최종소유자 : 김현수
최종소유자_주민번호 : 810126-*****

— 등록이력 (6건) —
[신규등록1]] 신규등록(신조차) **성명(서호).오.아** 781019-***** 은평구*... | 781019-*****
[변경등록1]] 변경등록 주소:서울특별시 은평구*****
[변경등록2]] 변경등록 주소:서울특별시 은평구*****
[변경등록3]] 변경등록 주소:서울특별시 은평구*****
[변경등록4]] **변경등록(단순전출) 성명(서호).오.아 781019-***** 경기도김포...**
[변경등록5]] 변경등록(전입) 서명(서명) ***** 781019-***... | 781019-*****



Thank you